

Laporan Tugas Pembelajaran Mesin



Dibuat Oleh:

Muhammad Naufal Zaki | 187241115

Parikesit Putra Pratomo | 187241053

SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS AIRLANGGA

Perbedaan Algoritma K-Means dan K-Modes

Dalam project ini, kita menggunakan dua algoritma clustering yang berbeda: K-Means dan K-Modes. Pemahaman perbedaan keduanya sangat penting karena masing-masing dirancang untuk tipe data yang berbeda.

K-Means Clustering (Untuk Data Numerik)

K-Means adalah algoritma clustering paling populer yang bekerja secara eksklusif dengan data numerik. Prinsip kerjanya adalah:

1. Inisialisasi: Algoritma memilih titik secara acak sebagai pusat cluster awal (centroid).
2. Assignment: Setiap data point ditugaskan ke centroid terdekat berdasarkan jarak Euclidean (jarak lurus antara dua titik dalam ruang multi-dimensi).
3. Update: Centroid diperbarui dengan menghitung rata-rata (mean) dari semua data point yang termasuk dalam cluster tersebut.
4. Iterasi: Langkah 2 dan 3 diulang sampai posisi centroid tidak berubah secara signifikan (konvergen).

K-Means sangat cocok untuk fitur seperti *Annual Income* dan *Spending Score* pada dataset Mall Customers, karena kedua fitur ini bersifat numerik kontinu dan jarak antar nilai memiliki makna matematis yang jelas.

K-Modes Clustering (Untuk Data Kategorikal)

K-Modes adalah ekstensi dari K-Means yang dirancang khusus untuk menangani data kategorikal. Perbedaan fundamentalnya terletak pada beberapa aspek:

1. Penggunaan Mode, Bukan Mean: Karena data kategorikal tidak memiliki konsep “rata-rata” (tidak bisa menjumlahkan “Laki-laki” dan “Perempuan” lalu dibagi 2), K-Modes menggunakan mode (nilai yang paling sering muncul) sebagai representasi pusat cluster.
2. Simple Matching Dissimilarity: Alih-alih jarak Euclidean, K-Modes menggunakan ukuran dissimilarity berbasis Simple Matching Coefficient.

Untuk dua record data, dissimilarity dihitung sebagai jumlah atribut yang memiliki nilai berbeda. Semakin banyak atribut yang cocok, semakin mirip kedua record tersebut.

3. Frequency-Based Update: Pusat cluster (centroid) diupdate berdasarkan frekuensi kemunculan masing-masing kategori dalam setiap atribut pada cluster tersebut.

Mengapa K-Modes Diperlukan dalam Project Ini?

K-Modes menjadi sangat diperlukan dalam project ini karena beberapa alasan:

1. Sifat Data yang Bervariasi: Dataset yang kita gunakan mengandung data kategorikal yang tidak bisa diproses oleh K-Means secara langsung. Pada dataset Mall Customers, meskipun fitur utama bersifat numerik, kita juga ingin memanfaatkan fitur kategorikal seperti *Gender* dan kelompok umur. Pada dataset Kartu Kredit, data yang sangat numerikal perlu didiskretisasi menjadi kategori untuk memudahkan interpretasi bisnis.
2. Interpretasi Bisnis yang Lebih Mudah: Hasil clustering dengan K-Modes menghasilkan profil cluster yang lebih intuitif dari sudut pandang bisnis. Misalnya, kita bisa mendeskripsikan sebuah cluster sebagai “Pengguna Muda dengan Pendapatan Rendah dan Pengeluaran Tinggi” — deskripsi yang langsung actionable untuk tim marketing.
3. Menghindari Asumsi Numerik yang Tidak Tepat: Jika kita memaksakan data kategorikal menjadi numerik (misalnya mengubah “Sangat Rendah”, “Rendah”, “Menengah”, “Tinggi”, “Sangat Tinggi” menjadi 1, 2, 3, 4, 5), K-Means akan mengasumsikan jarak antara “Sangat Rendah” ke “Rendah” sama dengan “Rendah” ke “Menengah”, yang belum tentu valid secara konseptual. K-Modes tidak membuat asumsi ini karena hanya memperhatikan apakah kategori sama atau berbeda.
4. Kepadatan Data yang Lebih Baik: Data kategorikal cenderung lebih padat (dense) dibanding data numerik yang bisa sangat sparse. K-Modes bekerja lebih efisien dengan struktur data semacam ini.

Tabel berikut merangkum perbedaan utama antara K-Means dan K-Modes:

Aspek	K-Means	K-Modes
Tipe Data	Numerik (kontinu atau diskrit)	Kategorikal (nominal atau ordinal)
Ukuran Pusat Cluster	Mean (rata-rata)	Mode (nilai terbanyak)
Metode Jarak	Jarak Euclidean	Simple Matching Dissimilarity
Metrik Evaluasi	Inertia (Within-Cluster Sum of Squares)	Cost (Total Dissimilarity)
Inisialisasi	K-Means++, random	Huang, Cao, random
Cocok Untuk	Data dengan jarak yang bermakna	Data dengan kategori yang bermakna

SEGMENTASI PELANGGAN MALL

Dataset: Mall_Customers.csv

Dataset Mall_Customers.csv berisi informasi demografis dan perilaku belanja dari 200 pelanggan sebuah pusat perbelanjaan. Dataset ini memiliki 5 kolom utama:

No	Fitur	Tipe Data	Deskripsi
1	CustomerID	Numerik	Identifikasi unik pelanggan
2	Gender	Kategorikal	Jenis kelamin pelanggan (Male/Female)
3	Age	Numerik	Usia pelanggan
4	Annual Income (k\$)	Numerik	Pendapatan tahunan dalam ribuan dolar

No	Fitur	Tipe Data	Deskripsi
5	Spending Score (1-100)	Numerik	Skor pengeluaran yang diberikan mall (1=terendah, 100=tertinggi)

Dataset ini sangat ideal untuk demonstrasi clustering karena memiliki fitur numerik yang kuat (Annual Income dan Spending Score) yang secara visual membentuk cluster yang jelas, serta fitur kategorikal (Gender) dan numerik lainnya (Age) yang dapat dikonversi menjadi kategori untuk K-Modes.

Eksplorasi Data (EDA)


Sebelum melakukan clustering, langkah pertama yang sangat penting adalah Exploratory Data Analysis (EDA) — proses mengamati, memahami, dan memvisualisasikan data untuk mendapatkan *insight* awal. Tahapan EDA membantu kita memahami distribusi data, mendeteksi outlier, melihat korelasi antar fitur, dan merumuskan hipotesis awal tentang kemungkinan struktur cluster.

Analisis Distribusi Fitur

Tahap awal EDA dilakukan dengan memeriksa distribusi dari tiga fitur numerik utama: Age (Usia), Annual Income (k\$) (Pendapatan Tahunan), dan Spending Score (1-100) (Skor Pengeluaran).

Untuk memahami distribusi masing-masing fitur, kita dapat menggunakan boxplot dan distplot (histogram dengan Kernel Density Estimation/KDE). Boxplot berguna untuk melihat median, kuartil, dan adanya outlier, sementara distplot memberikan gambaran bentuk distribusi secara keseluruhan.


Boxplot Analisis:



Dari visualisasi boxplot di atas, kita dapat mengamati beberapa hal penting:

- **Age (Usia):** Distribusi usia terlihat cukup simetris dengan median sekitar 35 tahun. Mayoritas pelanggan berusia antara 25-50 tahun, dengan beberapa outlier di usia ekstrem (sangat muda atau sangat tua). Rentang usia dari sekitar 18 hingga 70 tahun menunjukkan bahwa mall ini menarik bagi berbagai kalangan usia.
- **Annual Income (k\$):** Distribusi pendapatan menunjukkan median sekitar \$60k. Terdapat satu outlier yang signifikan pada pendapatan sekitar \$137k, yang perlu diperhatikan karena bisa mempengaruhi hasil clustering. Rentang pendapatan yang cukup luas (dari \$15k hingga \$137k) menunjukkan bahwa mall ini dikunjungi oleh pelanggan dari berbagai segmen ekonomi.
- **Spending Score (1-100):** Distribusi skor pengeluaran terlihat paling merata (uniform), dengan rentang penuh dari 1 hingga 100. Ini menunjukkan variasi perilaku belanja yang sangat beragam di antara pelanggan — ada yang sangat hemat (skor rendah) hingga yang sangat royal (skor tinggi).

Distplot (Histogram dengan KDE) Analisis:




Visualisasi distplot memberikan pemahaman lebih mendalam tentang bentuk distribusi:

- **Age:** Distribusi usia menunjukkan pola bimodal dengan dua puncak — satu di sekitar usia 20-30 tahun (pelanggan muda) dan puncak kedua di sekitar usia 30-40 tahun. Ini mengindikasikan bahwa mall ini memiliki dua segmen usia utama: anak muda dewasa awal dan dewasa paruh baya.
- **Annual Income:** Distribusi pendapatan cenderung normal dengan puncak di sekitar \$50k-\$70k. Ini berarti sebagian besar pelanggan memiliki pendapatan menengah, dengan jumlah pelanggan berpendapatan rendah dan tinggi yang lebih sedikit.
- **Spending Score:** Distribusi skor pengeluaran terlihat cukup uniform dengan sedikit konsentrasi di sekitar nilai 40-60, yang berarti mayoritas pelanggan memiliki perilaku pengeluaran moderat, dengan ekor panjang di kedua ujung (hemat dan royal).

Visualisasi Scatter Plot Berdasarkan Gender

Untuk melihat apakah ada pola berdasarkan gender, kita membuat scatter plot antara Annual Income dan Spending Score yang dibedakan berdasarkan warna untuk Male dan Female.



Dari scatter plot ini terlihat bahwa data point tersebar cukup merata tanpa adanya pemisahan yang jelas berdasarkan gender. Baik laki-laki maupun perempuan hadir di semua rentang pendapatan dan skor pengeluaran. Ini memberikan petunjuk bahwa gender mungkin bukan faktor pembeda utama dalam perilaku belanja, dan segmentasi yang lebih baik bisa diperoleh dari kombinasi pendapatan dan skor pengeluaran.

Matriks Korelasi antar Fitur

Untuk memahami hubungan linear antar fitur numerik, kita menggunakan pairplot dengan regresi yang menampilkan scatter plot antar semua pasangan fitur beserta garis regresi dan area kepercayaan.



Analisis Matriks Korelasi:

Matriks korelasi 3x3 ini menampilkan hubungan antara Age, Annual Income (k\$), dan Spending Score (1-100). Berikut interpretasi dari setiap pasangan fitur:

- Age vs Age (Diagonal kiri atas): Garis regresi linear sempurna dengan kemiringan positif, ini adalah variabel terhadap dirinya sendiri sehingga korelasinya pasti 1 (tidak memiliki makna analitis baru).
- Age vs Annual Income (baris 1, kolom 2): Terlihat garis regresi mendatar yang sangat landai, menunjukkan korelasi yang sangat lemah antara usia

dan pendapatan tahunan. Ini menarik karena secara umum diasumsikan bahwa pengalaman kerja bertambah seiring usia sehingga pendapatan juga meningkat, tetapi dalam dataset ini hubungan tersebut tidak terlihat signifikan. Data point menyebar secara acak di seluruh rentang pendapatan untuk setiap kelompok usia.

- Age vs Spending Score (baris 1, kolom 3): Terlihat korelasi negatif yang moderat. Garis regresi menurun dari kiri atas ke kanan bawah, yang mengindikasikan bahwa semakin tua usia pelanggan, cenderung semakin rendah spending score-nya. Ini masuk akal secara bisnis: pelanggan muda cenderung lebih impulsif dan lebih banyak berbelanja, sementara pelanggan lebih tua cenderung lebih hemat dan selektif dalam pengeluaran.
- Annual Income vs Age (baris 2, kolom 1): Sama seperti pasangan di atas, tidak ada korelasi yang signifikan.
- Annual Income vs Annual Income (Diagonal tengah): Garis regresi linear sempurna (variabel terhadap dirinya sendiri).
- Annual Income vs Spending Score (baris 2, kolom 3): Terlihat tidak ada korelasi linear yang signifikan. Garis regresi mendatar menunjukkan bahwa pendapatan tinggi tidak serta-merta berarti pengeluaran tinggi. Ini adalah insight yang sangat penting bagi strategi pemasaran — ada pelanggan berpenghasilan tinggi yang hemat, dan ada pelanggan berpenghasilan rendah yang royal. Pola inilah yang menjadi dasar utama dalam segmentasi pelanggan mall.
- Spending Score vs Age (baris 3, kolom 1): Korelasi negatif yang moderat (cerminan dari pasangan Age vs Spending Score).
- Spending Score vs Annual Income (baris 3, kolom 2): Tidak ada korelasi signifikan, mengkonfirmasi bahwa pendapatan dan pengeluaran tidak berjalan beriringan secara otomatis.
- Spending Score vs Spending Score (Diagonal kanan bawah): Garis regresi linear sempurna.

Insight Utama dari EDA: 1. Fitur Annual Income dan Spending Score tidak berkorelasi signifikan, yang berarti keduanya memberikan informasi yang berbeda dan saling melengkapi untuk clustering. 2. Terdapat korelasi negatif moderat antara Age dan Spending Score — pelanggan muda cenderung lebih banyak berbelanja. 3. Distribusi data yang bervariasi dan adanya outlier perlu diperhatikan dalam pemilihan algoritma clustering.

K-Means Clustering (Fitur Numerik)

Setelah memahami struktur data melalui EDA, langkah selanjutnya adalah melakukan clustering menggunakan K-Means pada fitur numerik utama: Annual Income (k\$) dan Spending Score (1-100). Kedua fitur ini dipilih karena: 1. Keduanya bersifat numerik kontinu — sangat cocok untuk K-Means 2. Keduanya tidak berkorelasi signifikan — memberikan informasi yang komplementer 3. Secara bisnis, kombinasi pendapatan dan perilaku belanja adalah dasar segmentasi pelanggan yang paling umum digunakan

Menentukan Jumlah Cluster Optimal dengan Elbow Method

Salah satu tantangan utama dalam K-Means adalah menentukan jumlah cluster (K) yang optimal. Elbow Method adalah teknik yang paling umum digunakan untuk tujuan ini. Metode ini bekerja dengan cara:

1. Menjalankan K-Means untuk berbagai nilai (dari 1 sampai 10)
2. Menghitung Inertia (Within-Cluster Sum of Squares/WCSS) untuk setiap K
3. Inertia mengukur total jarak kuadrat antara setiap data point dengan centroid cluster-nya. Semakin kecil inertia, semakin rapat data dalam cluster.
4. Memilih nilai di mana penurunan inertia mulai melambat secara signifikan — membentuk “siku” (elbow) pada grafik.

Berikut adalah kode untuk menjalankan Elbow Method:

```

X1 = df[['Annual Income (k$)', 'Spending Score (1-100)']].iloc[:,
:].values

inertia = []

for n in range(1, 11):

    algorithm = KMeans(n_clusters=n, init='k-means++', n_init=10,
max_iter=300, random_state=111)

    algorithm.fit(X1)


    inertia.append(algorithm.inertia_)

```

Penjelasan Kode:

- `X1 = df[['Annual Income (k$)', 'Spending Score (1-100)']].iloc[:, :].values` — Mengambil dua fitur utama dan mengkonversinya ke numpy array. Kedua fitur ini menjadi ruang 2-dimensi tempat clustering dilakukan.
- `inertia = []` — Membuat list kosong untuk menyimpan nilai inertia dari setiap K.
- `for n in range(1, 11)` — Melakukan iterasi untuk jumlah cluster dari 1 hingga 10. Nilai 1 digunakan sebagai baseline, sementara 10 adalah batas atas yang cukup untuk menemukan elbow.
- `KMeans(n_clusters=n, init='k-means++', n_init=10, max_iter=300, random_state=111)` — Membuat model K-Means dengan parameter:
 - `n_clusters=n` — Jumlah cluster yang akan diuji (berubah setiap iterasi)
 - `init='k-means++'` — Metode inisialisasi cerdas yang memilih centroid awal secara strategis untuk mempercepat konvergensi dan meningkatkan kualitas cluster
 - `n_init=10` — Algoritma dijalankan 10 kali dengan inisialisasi berbeda, dan hasil terbaik (inertia terendah) yang dipilih
 - `max_iter=300` — Batas maksimum iterasi untuk setiap run
 - `random_state=111` — Seed untuk reproducibility

- `algorithm.fit(X1)` — Melatih model pada data
- `inertia.append(algorithm.inertia_)` — Menyimpan nilai inertia total (jumlah jarak kuadrat dari setiap titik ke centroid cluster-nya) dari model yang dilatih.



Interpretasi Grafik Elbow Method:

Grafik Elbow Method di atas menunjukkan hubungan antara jumlah cluster (sumbu X) dan nilai inertia (sumbu Y):

- Pada $K = 1$, inertia memiliki nilai tertinggi (sekitar 270,000) karena semua data dianggap sebagai satu cluster.
- Penurunan inertia dari ke sangat drastis — dari ~270,000 ke ~180,000. Ini menunjukkan bahwa membagi data menjadi 2 cluster memberikan peningkatan yang sangat signifikan.
- Penurunan dari ke juga masih cukup besar — dari ~180,000 ke ~106,000.
- Penurunan dari ke terlihat — dari ~106,000 ke ~73,000.
- Penurunan dari ke masih signifikan — dari ~73,000 ke ~44,000.
- Penurunan dari ke mulai melambat secara drastis — dari ~44,000 ke ~37,000. Perbedaan ini jauh lebih kecil dibandingkan penurunan sebelumnya.
- Dari ke , penurunan inertia sangat gradual dan hampir datar.

Berdasarkan pola ini, titik “siku” (elbow) terjadi pada . Ini adalah nilai optimal karena: 1. Sebelum , penurunan inertia masih sangat signifikan — menambah

cluster memberikan peningkatan kualitas clustering yang besar. 2. Setelah , penurunan inertia menjadi sangat kecil — menambah cluster lebih lanjut tidak memberikan peningkatan kualitas yang proporsional dengan kompleksitas yang ditambahkan. 3. memberikan keseimbangan antara kesederhanaan model (parsimony) dan kualitas cluster.

Training Model K-Means dengan K=5

Setelah menentukan dari Elbow Method, kita melatih model K-Means final:

```
algorithm = KMeans(n_clusters=5, init='k-means++', n_init=10,
max_iter=300,

                    tol=0.0001, random_state=111, algorithm='elkan')

algorithm.fit(X1)

labels2 = algorithm.labels_


centroids2 = algorithm.cluster_centers_
```

Penjelasan Kode:

- `n_clusters=5` — Menggunakan 5 cluster sesuai hasil Elbow Method.
- `init='k-means++'` — Inisialisasi centroid secara cerdas untuk menghindari hasil yang buruk.
- `n_init=10` — Menjalankan algoritma 10 kali dan memilih hasil terbaik.
- `max_iter=300` — Batas iterasi maksimum.
- `tol=0.0001` — Toleransi konvergensi — algoritma berhenti jika perubahan posisi centroid kurang dari 0.01%.
- `algorithm='elkan'` — Menggunakan varian Elkan yang lebih cepat dengan menggunakan triangle inequality untuk mengurangi perhitungan jarak yang tidak perlu.
- `algorithm.fit(X1)` — Melatih model pada data.

- `labels2 = algorithm.labels_` — Mendapatkan label cluster untuk setiap data point (0, 1, 2, 3, atau 4).
- `centroids2 = algorithm.cluster_centers_` — Mendapatkan koordinat centroid (pusat) masing-masing 5 cluster.

Visualisasi Hasil Clustering



Interpretasi Visualisasi K-Means Clustering (K=5):

Visualisasi di atas menampilkan hasil clustering K-Means dengan 5 cluster yang berbeda warna pada ruang 2-dimensi (Annual Income vs Spending Score).

Berikut interpretasi detail dari setiap cluster:

Cluster Ungu (Kiri Atas) — “Pelanggan Hemat Berpenghasilan Rendah” -

Karakteristik: Pendapatan rendah (\$15k-\$40k) dan Spending Score tinggi (60-100) - Interpretasi: Pelanggan ini memiliki pendapatan terbatas tetapi cenderung royal dalam berbelanja. Mereka mungkin prioritas belanjanya tinggi meski pendapatan terbatas, atau mereka mungkin masih didukung finansial oleh orang tua (misalnya: anak muda yang masih tinggal dengan orang tua).

Cluster Hijau (Kanan Atas) — “Pelanggan Premium” - Karakteristik: Pendapatan tinggi (\$70k-\$140k) dan Spending Score tinggi (60-100) - Interpretasi: Ini adalah segmen paling bernilai — pelanggan kaya yang royal. Mereka adalah target utama untuk produk-produk premium dan *luxury goods*.

Cluster Kuning (Tengah) — “Pelanggan Rata-Rata” - Karakteristik: Pendapatan menengah (\$40k-\$60k) dan Spending Score menengah (40-60) - Interpretasi: Segmen terbesar yang menunjukkan perilaku “rata-rata”. Mereka berbelanja sesuai kemampuan dan cenderung lebih selektif. Ini adalah segmen yang bisa “dipengaruhi” dengan strategi marketing yang tepat.

Cluster Hijau Muda (Kanan Bawah) — “Pelanggan Kaya tapi Hemat” - Karakteristik: Pendapatan tinggi (\$70k-\$140k) tetapi Spending Score rendah (1-40) - Interpretasi: Pelanggan berpenghasilan tinggi yang sangat hemat dalam berbelanja. Mereka mungkin lebih suka menabung atau berinvestasi. Untuk segmen ini, strategi marketing perlu menekankan nilai dan kualitas produk.

Cluster Hijau Tua (Kiri Bawah) — “Pelanggan Pendapatan Rendah dan Hemat” - Karakteristik: Pendapatan rendah (\$15k-\$40k) dan Spending Score rendah (1-40) - Interpretasi: Pelanggan dengan daya beli terbatas yang juga sangat selektif dalam berbelanja. Mereka cenderung mencari barang-barang yang paling murah atau diskon besar.

Titik-titik merah adalah centroid dari masing-masing cluster — pusat matematis yang mewakili rata-rata karakteristik dari setiap segmen.

Evaluasi dengan Silhouette Score

Setelah melatih model, kita perlu mengukur kualitas cluster yang terbentuk menggunakan Silhouette Score. Metrik ini mengukur seberapa “mirip” sebuah objek dengan cluster-nya sendiri (kohesi) dibandingkan dengan cluster terdekat lainnya (pemisahan).

```
algorithm = KMeans(n_clusters=5, init='k-means++', n_init=10,
algorithm='elkan')

algorithm.fit(X1)

score2 = silhouette_score(X1, algorithm.labels_)

print("Silhouette Score:", score2)
```

Penjelasan Kode:

- `silhouette_score(X1, algorithm.labels_)` — Menghitung Silhouette Score rata-rata untuk semua data point. Nilai berkisar dari -1 hingga 1:
 - : Data point sangat cocok dengan cluster-nya dan jauh dari cluster lain (clustering sempurna)
 - : Data point berada di batas antara dua cluster (tumpang tindih)
 - -1: Data point mungkin salah cluster

Berdasarkan output dari kode, Silhouette Score yang diperoleh sekitar 0.55, yang menunjukkan bahwa struktur cluster yang terbentuk memiliki kualitas moderat hingga baik. Data point cenderung berdekatan dengan centroid cluster-nya sendiri dan cukup terpisah dari cluster lainnya. Meskipun tidak sempurna (nilai di atas 0.70 dianggap sangat baik), nilai ini sudah cukup memuaskan untuk analisis bisnis dan memberikan insight yang actionable.

K-Modes Clustering (Fitur Kategorikal)

Selain K-Means yang bekerja pada data numerik, project ini juga menerapkan K-Modes Clustering untuk mendapatkan segmentasi berbasis kategori.

Pendekatan ini dilakukan karena beberapa alasan: 1. Interpretasi Bisnis yang Lebih Mudah: Cluster berbasis kategori (misalnya: “Pria Dewasa Muda dengan Pendapatan Menengah dan Pengeluaran Tinggi”) lebih mudah diinterpretasikan dan diimplementasikan oleh tim marketing. 2. Memanfaatkan Semua Fitur: K-Modes memungkinkan kita memanfaatkan fitur kategorikal seperti Gender bersama dengan fitur numerik yang telah didiskretisasi. 3. Tidak Ada Asumsi Jarak: K-Modes tidak mengasumsikan jarak antar nilai kategori, yang lebih valid secara konseptual.

Preprocessing: Teknik Binning

Sebelum data dapat diproses oleh K-Modes, fitur numerik perlu diubah menjadi kategori melalui teknik binning (pengelompokan ke dalam rentang/range):

```
df_kmodes = df.copy() # Binning Age (Usia) menjadi kelompok kategori
```

```

df_kmodes['Age_Group'] = pd.cut(df['Age'], bins=[0, 25, 35, 45, 55,
100], labels=['Remaja', 'Dewasa Muda', 'Dewasa', 'Paruh Baya',
'Lansia']) # Binning Annual Income menjadi kelompok pendapatan

df_kmodes['Income_Group'] = pd.cut(df['Annual Income (k$)'],
bins=[0, 30, 60, 90, 120, 200], labels=['Sangat Rendah', 'Rendah',
'Menengah', 'Tinggi', 'Sangat Tinggi']) # Binning Spending Score
menjadi kelompok pengeluaran

df_kmodes['Spending_Group'] = pd.cut(df['Spending Score (1-100)'],
bins=[0, 20, 40, 60, 80, 100], labels=['Sangat Rendah', 'Rendah',
'Menengah', 'Tinggi', 'Sangat Tinggi']) # Memilih fitur kategorikal
untuk K-Modes

X_kmodes = df_kmodes[['Gender', 'Age_Group', 'Income_Group',
'Spending_Group']].astype(str)

```

Penjelasan Kode:


- `df_kmodes = df.copy()` — Membuat salinan dataframe asli agar data asli tetap terjaga.
- `pd.cut(df['Age'], bins=[0, 25, 35, 45, 55, 100], labels=[...])` — Menggunakan pandas `cut()` untuk membuat binning dengan rentang tetap (equal-width binning):
 - Remaja: 0-25 tahun (umumnya pelajar/mahasiswa)
 - Dewasa Muda: 25-35 tahun (awal karir)
 - Dewasa: 35-45 tahun (puncak karir)
 - Paruh Baya: 45-55 tahun (manajerial)
 - Lansia: 55+ tahun (mendekati pensiun)
- `pd.cut(df['Annual Income (k$)'], bins=[0, 30, 60, 90, 120, 200], labels=[...])` — Binning pendapatan:
 - Sangat Rendah: \$0-\$30k
 - Rendah: \$30k-\$60k
 - Menengah: \$60k-\$90k

- Tinggi: \$90k-\$120k
 - Sangat Tinggi: \$120k+
- `pd.cut(df['Spending Score (1-100)'], bins=[0, 20, 40, 60, 80, 100], labels=[...])` — Binning skor pengeluaran:
 - Sangat Rendah: 1-20
 - Rendah: 21-40
 - Menengah: 41-60
 - Tinggi: 61-80
 - Sangat Tinggi: 81-100
- `.astype(str)` — Mengkonversi semua kategori ke string karena K-Modes mengharapkan input dalam format string.

Elbow Method untuk K-Modes

Seperti K-Means, K-Modes juga menggunakan Elbow Method untuk menentukan jumlah cluster optimal, hanya saja yang diplot adalah Cost (Total Dissimilarity) bukan Inertia:

```
cost = []
K_range = range(2, 11)
for k in K_range: km = KModes(n_clusters=k, init='Huang', n_init=10,
verbose=0) km.fit(X_kmodes) cost.append(km.cost_)
```



Interpretasi Elbow Method K-Modes:

Grafik di atas menunjukkan Cost (Total Dissimilarity) untuk berbagai nilai K:

- Penurunan cost dari ke sangat signifikan (dari ~360 ke ~315)
- Penurunan dari ke juga masih cukup besar (dari ~315 ke ~288)
- Penurunan dari ke mulai melambat
- Setelah $K = 5$, penurunan cost menjadi sangat gradual

Berdasarkan grafik ini, dipilih sebagai jumlah cluster optimal karena merupakan titik “siku” yang jelas — setelah 4 cluster, penurunan cost tidak lagi signifikan.

Training Model K-Modes dengan K=4

```
km_model = KModes(n_clusters=4, init='Huang', n_init=10, verbose=0,
random_state=42)


clusters_kmodes = km_model.fit_predict(X_kmodes)
```

Penjelasan Kode:

- `KModes(n_clusters=4, ...)` — Menggunakan 4 cluster sesuai hasil Elbow Method.
- `init='Huang'` — Metode inisialisasi Huang yang dirancang khusus untuk K-Modes. Metode ini mencoba menempatkan centroid awal di lokasi yang strategis berdasarkan frekuensi kategori.

- `n_init=10` — Menjalankan algoritma 10 kali dengan inisialisasi berbeda untuk menghindari local optimum.
- `verbose=0` — Menyembunyikan output iterasi untuk menjaga kebersihan output.
- `random_state=42` — Seed untuk reproducibility.
- `fit_predict(X_kmodes)` — Melatih model dan sekaligus mengembalikan label cluster untuk setiap data point.

Analisis Hasil K-Modes Clustering



Interpretasi Visualisasi Distribusi dan Komposisi Gender per Cluster:


Visualisasi di atas menampilkan dua grafik: distribusi jumlah anggota per cluster (kiri) dan komposisi gender per cluster (kanan).

Dari grafik distribusi anggota (kiri): - Cluster 0: 82 anggota (terbesar, ~41% dari total) - Cluster 1: 37 anggota (~18.5%) - Cluster 2: 37 anggota (~18.5%) - Cluster 3: 44 anggota (~22%)

Dari grafik komposisi gender (kanan): - Cluster 0: Didominasi oleh Female (sekitar 55 wanita vs 25 pria). Cluster ini adalah cluster wanita terbesar. - Cluster 1: Didominasi oleh Female (sekitar 25 wanita vs 12 pria), tetapi dengan jumlah total yang lebih kecil. - Cluster 2: Didominasi oleh Female (sekitar 25 wanita vs 10 pria). - Cluster 3: Didominasi oleh Male (sekitar 37 pria vs 7 wanita). Ini adalah satu-satunya cluster yang didominasi pria.

Insight dari Komposisi Gender: Pola ini menarik — 3 dari 4 cluster didominasi oleh wanita, yang mengindikasikan bahwa dalam dataset ini, wanita memiliki variasi perilaku belanja yang lebih besar dan membentuk pola-pola cluster yang

lebih beragam. Pria cenderung terkonsentrasi dalam satu cluster (Cluster 3), yang mungkin menunjukkan perilaku belanja pria yang lebih homogen.



Interpretasi Visualisasi K-Modes pada Annual Income vs Spending Score:

Visualisasi scatter plot ini menunjukkan posisi masing-masing cluster dalam ruang pendapatan dan pengeluaran, dengan marker yang berbeda untuk setiap cluster:

- Cluster 0 (Lingkaran Merah, n=82): Sebagian besar berkumpul di area pendapatan menengah-rendah (\$40k-\$70k) dengan spending score menengah (40-60). Ini adalah cluster terbesar yang mewakili “pelanggan mainstream”.
- Cluster 1 (Kotak Hijau, n=37): Menyebar di area pendapatan tinggi (\$80k-\$140k) dengan spending score rendah-menengah (0-40). Ini adalah cluster “pelanggan kaya tapi hemat”.
- Cluster 2 (Segitiga Biru, n=37): Menyebar di area pendapatan rendah-menengah (\$15k-\$40k) dengan spending score bervariasi rendah hingga tinggi. Ini adalah cluster “pelanggan dengan gaya hidup beragam”.

- Cluster 3 (Berlian Oranye, n=44): Sebagian besar berkumpul di area pendapatan menengah-tinggi (\$60k-\$100k) dengan spending score tinggi (60-95). Ini adalah cluster “pelanggan royal dengan pendapatan baik”.

Karakteristik Detail Setiap Cluster K-Modes:

Cluster	Gender Dominan	Age Group Dominan	Income Dominan	Spending Dominan	Interpretasi Bisnis
0	Female	Dewasa Muda/Dewasa	Menengah	Menengah	Wanita Mainstream — Pelanggan wanita dengan pendapatan dan pengeluaran rata-rata, membentuk segmen terbesar
1	Female	Paruh Baya/Dewasa	Tinggi	Rendah-Menengah	Wanita Hemat Berpenghasilan — Wanita berpenghasilan tinggi yang selektif dalam berbelanja
2	Female	Remaja/Dewasa Muda	Rendah	Sangat Rendah-Tinggi	Wanita Muda Variatif — Wanita muda dengan pendapatan terbatas namun variasi

Cluster	Gender Dominan	Age Group Dominan	Income Dominan	Spending Dominan	Interpretasi Bisnis
					pengeluaran yang besar
3	Male	Dewasa	Menengah-Tinggi	Tinggi-Sangat Tinggi	Pria Royal — Pria dengan pendapatan baik dan pengeluaran tinggi, segmen yang sangat bernilai

SEGMENTASI KARTU KREDIT

Dataset: CC GENERAL.csv

Dataset CC GENERAL.csv adalah dataset komprehensif yang berisi informasi perilaku penggunaan kartu kredit dari 8.950 nasabah sebuah bank. Dataset ini memiliki 18 atribut yang mencakup berbagai aspek transaksi dan perilaku keuangan nasabah, menjadikannya sumber data yang sangat kaya untuk analisis segmentasi.

Daftar Fitur Dataset

No	Fitur	Tipe Data	Deskripsi
1	CUST_ID	Kategorikal	ID unik nasabah
2	BALANCE	Numerik	Saldo rata-rata yang tersisa di akun
3	BALANCE_FREQUENCY	Numerik	Frekuensi saldo diperbarui (0-1)

No	Fitur	Tipe Data	Deskripsi
4	PURCHASES	Numerik	Total jumlah pembelian
5	ONEOFF_PURCHASES	Numerik	Total pembelian satu kali (sekali bayar)
6	INSTALLMENTS_PURCHASES	Numerik	Total pembelian dengan cicilan
7	CASH_ADVANCE	Numerik	Total penarikan tunai
8	PURCHASES_FREQUENCY	Numerik	Frekuensi pembelian (0-1)
9	ONEOFF_PURCHASES_FREQUENCY	Numerik	Frekuensi pembelian satu kali
10	PURCHASES_INSTALLMENTS_FREQUENCY	Numerik	Frekuensi pembelian cicilan
11	CASH_ADVANCE_FREQUENCY	Numerik	Frekuensi penarikan tunai
12	CASH_ADVANCE_TRX	Numerik	Jumlah transaksi penarikan tunai
13	PURCHASES_TRX	Numerik	Jumlah transaksi pembelian

No	Fitur	Tipe Data	Deskripsi
14	CREDIT_LIMIT	Numerik	Batas kredit kartu kredit
15	PAYMENTS	Numerik	Total pembayaran yang dilakukan
16	MINIMUM_PAYMENTS	Numerik	Total pembayaran minimum
17	PRC_FULL_PAYMENT	Numerik	Persentase pembayaran penuh (0-1)
18	TENURE	Numerik	Masa hubungan dengan bank (bulan)

Dataset ini sangat cocok untuk K-Modes clustering karena semua fitur numeriknya merepresentasikan aspek perilaku finansial yang berbeda, dan ketika didiskretisasi menjadi kategori (Rendah, Sedang, Tinggi), akan memberikan profil nasabah yang sangat intuitif secara bisnis.

Preprocessing Data (Imputasi dan Diskretisasi)

Data yang berkualitas adalah fondasi dari analisis yang berkualitas. Sebelum melakukan clustering, dataset kartu kredit perlu melalui beberapa tahapan preprocessing penting.

Menangani Missing Values (Imputasi)

Langkah pertama dalam preprocessing adalah memeriksa dan menangani nilai yang hilang (missing values). Missing values dapat menyebabkan error dalam algoritma machine learning dan mengurangi kualitas hasil clustering.

```
# Import dan amati data
```

```

import pandas as pd

import numpy as np

import matplotlib.pyplot as plt

import seaborn as sns

from kmodes.kmodes import KModes

from sklearn.metrics import silhouette_score # Import data

df = pd.read_csv('CC_GENERAL.csv') # Cek null data

print('Jumlah nilai null per kolom:')

print(df.isnull().sum())

print(f'\nTotal nilai null: {df.isnull().sum().sum()}')

```

Dari hasil pengecekan, ditemukan bahwa terdapat nilai null pada beberapa kolom, terutama di kolom CREDIT_LIMIT dan MINIMUM_PAYMENTS. Nilai null ini perlu ditangani sebelum melanjutkan ke tahap clustering.

```

# Tangani missing values terlebih dahulu

df_clean = df.copy() # Isi CREDIT_LIMIT dan MINIMUM_PAYMENTS yang
null dengan median

df_clean['CREDIT_LIMIT'].fillna(df_clean['CREDIT_LIMIT'].median(),
inplace=True)

df_clean['MINIMUM_PAYMENTS'].fillna(df_clean['MINIMUM_PAYMENTS'].med
ian(), inplace=True) print('Cek null setelah handling:')

print(df_clean.isnull().sum()[df_clean.isnull().sum() > 0])

print('Tidak ada lagi nilai null.' if df_clean.isnull().sum().sum()
== 0 else 'Masih ada nilai null.')

```

Penjelasan Kode:

- `df_clean = df.copy()` — Membuat salinan dataframe untuk menjaga data asli tetap utuh.
- `df_clean['CREDIT_LIMIT'].fillna(df_clean['CREDIT_LIMIT'].median(), inplace=True)` — Mengisi nilai null pada kolom CREDIT_LIMIT dengan median. Median dipilih daripada mean karena data finansial cenderung memiliki distribusi *right-skewed* (condong ke kanan) dengan adanya outlier. Mean sangat sensitif terhadap outlier, sementara median lebih robust.
- `df_clean['MINIMUM_PAYMENTS'].fillna(df_clean['MINIMUM_PAYMENTS'].median(), inplace=True)` — Sama seperti di atas, mengisi nilai null MINIMUM_PAYMENTS dengan median.
- `inplace=True` — Modifikasi dilakukan langsung pada dataframe tanpa perlu assignment ulang.

Mengapa Median dipilih?

Karena data finansial seperti CREDIT_LIMIT dan MINIMUM_PAYMENTS biasanya memiliki distribusi yang tidak normal dengan adanya outlier (beberapa nasabah mungkin memiliki limit kredit yang sangat tinggi), median adalah pilihan yang lebih baik daripada mean untuk imputasi. Median merepresentasikan nilai tengah yang lebih robust dan tidak terpengaruh oleh nilai ekstrem.

Seleksi Fitur

Setelah menangani missing values, langkah selanjutnya adalah memilih fitur yang paling relevan untuk clustering. Tidak semua 18 fitur perlu digunakan — kita memilih 8 fitur yang paling representatif:

```
# Pilih fitur yang relevan untuk clustering

features = ['BALANCE', 'PURCHASES', 'CASH_ADVANCE', 'CREDIT_LIMIT',
            'PAYMENTS', 'MINIMUM_PAYMENTS', 'PRC_FULL_PAYMENT', 'TENURE']
df_selected = df_clean[features].copy()

print('Fitur yang dipilih:', features)
```

Alasan Pemilihan Fitur:

Fitur	Alasan Dipilih
BALANCE	Menunjukkan besar saldo yang sering dipertahankan — indikator apakah nasabah “revolver” (menyimpan saldo) atau “transactor” (membayar penuh)
PURCHASES	Total volume pembelian — indikator aktivitas transaksi utama
CASH_ADVANCE	Penarikan tunai yang sering menunjukkan kebutuhan likuiditas mendesak — indikator potensi risiko
CREDIT_LIMIT	Batas kredit yang mencerminkan kepercayaan bank dan profil kredit nasabah
PAYMENTS	Total pembayaran yang dilakukan — indikator kemampuan dan kesediaan membayar
MINIMUM_PAYMENTS	Total pembayaran minimum — bisa mengindikasikan perilaku pembayaran minimum
PRC_FULL_PAYMENT	Persentase pembayaran penuh — indikator kunci dari disiplin keuangan nasabah
TENURE	Lama hubungan dengan bank — indikator loyalitas dan umur akun

Diskretisasi dengan Quantile-Based Binning (qcut)

Karena K-Modes hanya bekerja dengan data kategorikal, kita perlu mengubah 8 fitur numerik yang telah dipilih menjadi kategori. Teknik yang digunakan adalah quantile-based binning menggunakan `pd.qcut()`:

```
# Diskretisasi: ubah fitur numerik menjadi kategori dengan qcut
(kuantil-based)

df_cat = pd.DataFrame() bin_labels = ['Rendah', 'Sedang', 'Tinggi']
for col in features: binned = pd.qcut(df_selected[col], q=3,
labels=False, duplicates='drop') n_bins = len(binned.unique())
labels = bin_labels[:n_bins] df_cat[col] = pd.qcut(df_selected[col],
q=3, labels=labels, duplicates='drop') # Ubah ke tipe object
(string) agar kompatibel dengan K-Modes

df_cat = df_cat.astype(str)
```

Penjelasan Kode:

- `pd.qcut(df_selected[col], q=3, ...)` — Menggunakan `qcut` (quantile cut) untuk membagi data menjadi 3 kuantil (tertil/quantile) yang sama besar:
 - Kuantil 1 (33.3% data terendah) → 'Rendah'
 - Kuantil 2 (33.3% data tengah) → 'Sedang'
 - Kuantil 3 (33.3% data tertinggi) → 'Tinggi'
- `labels=['Rendah', 'Sedang', 'Tinggi']` — Memberikan label kategori yang intuitif dalam bahasa Indonesia.
- `duplicates='drop'` — Menangani kasus di mana banyak data memiliki nilai yang sama (terutama fitur dengan banyak nilai nol seperti `CASH_ADVANCE`), yang bisa menyebabkan bin boundary yang duplikat. Parameter ini secara otomatis menangani masalah tersebut dengan menjatuhkan bin yang bertumpang tindih.


- `labels=False` pada baris pertama untuk menghitung jumlah bin unik yang sebenarnya terbentuk, kemudian labels yang sesuai diterapkan pada baris kedua.
- `df_cat = df_cat.astype(str)` — Konversi ke tipe string yang diharapkan oleh K-Modes.

Keuntungan Menggunakan `qcut`:

1. Distribusi Merata: Setiap kategori ('Rendah', 'Sedang', 'Tinggi') akan memiliki jumlah data yang kurang lebih sama, menghindari kategori yang terlalu dominan atau terlalu jarang.
2. Adaptif terhadap Distribusi Data: `qcut` secara otomatis menyesuaikan batas bin berdasarkan distribusi data, berbeda dengan `cut` yang menggunakan rentang tetap. Ini sangat penting untuk data finansial yang sering *skewed*.
3. Interpretasi Bisnis yang Jelas: Label 'Rendah', 'Sedang', 'Tinggi' sangat intuitif dan mudah dipahami oleh stakeholder bisnis.

Visualisasi Distribusi Kategori

Setelah diskretisasi, penting untuk memvisualisasikan distribusi kategori untuk setiap fitur guna memastikan proses binning berhasil dan memahami karakteristik data.



Interpretasi Distribusi Kategori:

Visualisasi di atas menampilkan distribusi kategori ('Rendah', 'Sedang', 'Tinggi') untuk masing-masing 8 fitur:

BALANCE: Distribusi cukup seimbang di ketiga kategori (masing-masing sekitar 2,983 nasabah). Ini menunjukkan bahwa saldo nasabah terdistribusi merata di seluruh rentang.

PURCHASES: Distribusi hampir merata (Rendah: 2,984; Tinggi: 2,983; Sedang: 2,983). Nasabah terbagi sama rata antara pembeli rendah, sedang, dan tinggi.

CASH_ADVANCE: Distribusi tidak seimbang — kategori 'Rendah' mendominasi dengan 5,967 nasabah (66.7%), sementara 'Sedang' hanya 2,983 nasabah. Ini menunjukkan bahwa sebagian besar nasabah tidak melakukan penarikan tunai sama sekali atau dalam jumlah sangat kecil — sebuah insight penting tentang perilaku penggunaan kartu kredit.

CREDIT_LIMIT: Distribusi seimbang (Sedang: 3,061; Rendah: 2,990; Tinggi: 2,898). Ini menunjukkan bahwa bank telah menerbitkan kartu kredit dengan batas kredit yang cukup terdistribusi di semua segmen.

PAYMENTS: Distribusi merata (~2,983 per kategori). Pembayaran nasabah tersebar secara merata di semua tingkat.

MINIMUM_PAYMENTS: Distribusi merata (~2,879 per kategori). Pola pembayaran minimum juga terdistribusi dengan baik.

PRC_FULL_PAYMENT: Distribusi tidak seimbang — kategori 'Rendah' sangat mendominasi dengan 6,329 nasabah (70.7%). Ini mengindikasikan bahwa sebagian besar nasabah tidak membayar tagihan penuh setiap bulan — mereka adalah “revolvers” yang membiarkan saldo mengendap dan membayar bunga.


TENURE: Distribusi tidak seimbang — kategori 'Rendah' mendominasi dengan 8,950 nasabah (100%). Ini menunjukkan bahwa semua nasabah dalam dataset memiliki tenure yang relatif sama/rendah, yang bisa mengindikasikan bahwa dataset ini berasal dari nasabah-nasabah baru atau dataset hanya mencakup periode tertentu.

Insight Utama dari Distribusi: 1. Mayoritas nasabah tidak melakukan penarikan tunai (CASH_ADVANCE dominan di kategori Rendah). 2. Sebagian besar nasabah tidak membayar penuh tagihan mereka setiap bulan

(PRC_FULL_PAYMENT dominan di kategori Rendah), yang berarti mereka adalah sumber pendapatan bunga bagi bank. 3. TENURE hampir semuanya di kategori 'Rendah', yang bisa menjadi keterbatasan dalam analisis ini.

Analisis Korelasi antar Fitur Numerik

Sebelum melakukan clustering, mari kita lihat korelasi antar fitur numerik asli:



Interpretasi Heatmap Korelasi:

Heatmap korelasi menunjukkan hubungan linear antar fitur numerik yang dipilih.

Berikut insight pentingnya:

- **BALANCE vs CASH_ADVANCE (0.50):** Korelasi positif moderat. Nasabah dengan saldo tinggi cenderung juga memiliki penarikan tunai yang tinggi. Ini masuk akal karena penarikan tunai biasanya dikenakan bunga sejak hari pertama, sehingga cenderung meningkatkan saldo.

- **BALANCE vs CREDIT_LIMIT (0.53):** Korelasi positif moderat. Batas kredit yang lebih tinggi memungkinkan nasabah untuk mempertahankan saldo yang lebih tinggi.
- **BALANCE vs MINIMUM_PAYMENTS (0.40):** Korelasi positif moderat. Semakin tinggi saldo, semakin tinggi pembayaran minimum yang harus dibayar.
- **PURCHASES vs PAYMENTS (0.60):** Korelasi positif cukup kuat. Nasabah yang banyak berbelanja cenderung juga banyak melakukan pembayaran. Ini menunjukkan perilaku nasabah yang menggunakan kartu kredit secara aktif untuk transaksi sehari-hari.
- **PURCHASES vs ONEOFF_PURCHASES (korelasi tinggi):** Korelasi sangat tinggi karena ONEOFF_PURCHASES adalah bagian dari total PURCHASES.
- **BALANCE vs PRC_FULL_PAYMENT (-0.32):** Korelasi negatif moderat. Nasabah dengan saldo tinggi cenderung memiliki persentase pembayaran penuh yang rendah — ini menunjukkan bahwa nasabah yang menumpuk saldo biasanya tidak membayar tagihan penuh.
- **CASH_ADVANCE vs PRC_FULL_PAYMENT (-0.15):** Korelasi negatif lemah. Nasabah yang sering melakukan penarikan tunai cenderung tidak membayar penuh.

Insight dari Korelasi:

Korelasi-korelasi ini memberikan gambaran awal tentang perilaku nasabah.

Korelasi positif antara PURCHASES dan PAYMENTS menunjukkan ada segmen nasabah “aktif transaksi”, sementara korelasi negatif antara BALANCE dan PRC_FULL_PAYMENT mengindikasikan adanya segmen “revolver” yang mengandalkan kartu kredit sebagai sumber pendanaan. Pola-pola inilah yang akan diungkap lebih detail oleh K-Modes clustering.

Penentuan Cluster (K-Modes)

Elbow Method untuk Menentukan Jumlah Cluster

Seperti pada analisis Mall Customers, kita menggunakan Elbow Method untuk menentukan jumlah cluster optimal. Untuk K-Modes, yang diplot adalah Cost (Total Dissimilarity) — total perbedaan antara setiap data point dengan mode (centroid) cluster-nya.

```
# Handle NaN values in df_cat before K-Modes

df_cat_clean = df_cat.fillna(df_cat.mode().iloc[0]) # Elbow Method
untuk K-Modes

cost_list = []


K_range = range(1, 11) print('Menghitung cost untuk setiap nilai
K...')

for k in K_range: km = KModes(n_clusters=k, init='Huang', n_init=5,
verbose=0, random_state=42) km.fit(df_cat_clean)
cost_list.append(km.cost_) print(f' K={k}, Cost={km.cost_:.2f}')
```

Penjelasan Kode:

- `df_cat_clean = df_cat.fillna(df_cat.mode().iloc[0])` — Menangani nilai NaN yang mungkin tersisa setelah `qcut` (jika ada) dengan mengisi menggunakan mode (nilai paling sering muncul) dari masing-masing kolom. Ini konsisten dengan filosofi K-Modes yang menggunakan mode.
- `KModes(n_clusters=k, init='Huang', n_init=5, ...)` — Membuat model K-Modes dengan:
 - `init='Huang'` — Metode inisialisasi Huang yang efisien untuk data kategorikal
 - `n_init=5` — Menjalankan 5 kali dengan inisialisasi berbeda untuk mendapatkan hasil optimal
 - `random_state=42` — Seed untuk reproducibility

- `km.cost_` — Atribut yang menyimpan total cost (dissimilarity) dari model yang dilatih. Cost ini adalah jumlah dari semua perbedaan atribut antara setiap data point dengan centroid cluster-nya.



Interpretasi Grafik Elbow Method K-Modes Kartu Kredit:

Grafik Elbow Method di atas menunjukkan pola penurunan cost untuk K dari 1 hingga 10:

- K=1: Cost tertinggi (~35,000) karena semua data dalam satu cluster.
- K=1 ke K=2: Penurunan sangat drastis — dari ~35,000 ke ~24,500. Penurunan lebih dari 10,000 unit menunjukkan bahwa membagi data menjadi 2 cluster memberikan perbaikan yang sangat signifikan.
- K=2 ke K=3: Penurunan masih signifikan — dari ~24,500 ke ~20,000. Penurunan ~4,500 unit masih cukup besar.
- K=3 ke K=4: Penurunan lebih kecil — dari ~20,000 ke ~18,900. Penurunan mulai melambat.
- K=4 ke K=5: Penurunan semakin kecil — dari ~18,900 ke ~16,500.
- K=5 ke K=10: Penurunan cost sangat gradual dan hampir datar.

Berdasarkan grafik ini, titik “siku” (elbow) terjadi di K=3. Ini adalah nilai optimal karena: 1. Sebelum K=3, penurunan cost masih sangat signifikan 2. Setelah

K=3, penurunan cost mulai melambat secara drastis 3. K=3 memberikan keseimbangan antara kompleksitas model dan kualitas cluster

Training Model K-Modes dengan K=3

Berdasarkan hasil Elbow Method, kita menggunakan K=3 sebagai jumlah cluster optimal:

```
# Membangun K-Modes dengan K optimal

optimal_k = 3 # Ditentukan dari Elbow Method km_model = KModes(
n_clusters=optimal_k, init='Huang', # Metode inisialisasi: 'Huang'
atau 'Cao' n_init=10, # Jumlah inisialisasi verbose=0,
random_state=42

) cluster_labels = km_model.fit_predict(df_cat_clean)
print(f'K-Modes berhasil dibangun dengan K = {optimal_k}')

print(f'Total Cost (Dissimilarity): {km_model.cost_:.4f}')

print(f'Jumlah iterasi sampai konvergen: {km_model.n_iter_}')
```

Penjelasan Kode:

- `optimal_k = 3` — Jumlah cluster yang ditentukan dari analisis Elbow Method.
- `init='Huang'` — Metode inisialisasi Huang, yang merupakan metode default dan direkomendasikan untuk K-Modes. Metode ini mencoba menempatkan centroid awal di lokasi yang memaksimalkan frekuensi kategori dominan.
- `n_init=10` — Menjalankan algoritma 10 kali dengan inisialisasi yang berbeda dan memilih model dengan cost terendah. Ini penting karena K-Modes, seperti K-Means, sensitif terhadap inisialisasi awal dan bisa terjebak dalam local optimum.
- `fit_predict(df_cat_clean)` — Melatih model pada data kategorikal yang sudah bersih dan mengembalikan label cluster untuk setiap nasabah (0, 1, atau 2).

- `km_model.cost_` — Total dissimilarity dari model optimal — semakin rendah nilai ini, semakin baik kualitas cluster.
- `km_model.n_iter_` — Jumlah iterasi yang dibutuhkan hingga model konvergen.

Analisis Cluster Centroids (Mode)

Salah satu keuntungan utama K-Modes adalah interpretability — kita bisa melihat “mode” (nilai paling sering muncul) dari setiap atribut untuk masing-masing cluster:

```
# Melihat Cluster Centroids (Mode)

centroids_df = pd.DataFrame(km_model.cluster_centroids_,
                             columns=features)

centroids_df.index = [f'Cluster {i}' for i in range(optimal_k)]
print('Cluster Centroids (Mode tiap cluster):')

centroids_df
```

Cluster centroid menunjukkan nilai kategori yang paling representatif untuk masing-masing cluster. Ini seperti “profil tipikal” dari nasabah di setiap cluster.

Evaluasi dengan Silhouette Score (Menggunakan Jarak Hamming)

Meskipun K-Modes bekerja dengan data kategorikal, Silhouette Score memerlukan data numerik untuk menghitung jarak. Oleh karena itu, kita mengubah kategori menjadi numerik menggunakan Label Encoding dan menggunakan `metric='hamming'`:

```
from sklearn.preprocessing import LabelEncoder # Encode data
kategorik ke numerik untuk perhitungan silhouette

df_encoded = df_cat.copy()

le = LabelEncoder()

for col in df_encoded.columns: df_encoded[col] =
le.fit_transform(df_encoded[col]) # Hitung silhouette score
```

```
sil_score = silhouette_score(df_encoded, cluster_labels,
metric='hamming')

print(f'Silhouette Score (Hamming): {sil_score:.4f}')
```


Penjelasan Kode:

- `LabelEncoder()` — Mengubah setiap kategori string menjadi nilai numerik (0, 1, 2). Perlu dicatat bahwa encoding ini hanya untuk perhitungan jarak — tidak ada asumsi ordinalitas.
- `metric='hamming'` — Jarak Hamming menghitung jumlah atribut yang berbeda antara dua record, dibagi dengan jumlah total atribut. Ini konsisten dengan prinsip Simple Matching yang digunakan oleh K-Modes. Dua nasabah dengan kategori yang sama di semua 8 fitur akan memiliki jarak Hamming = 0, sementara nasabah yang berbeda di semua fitur akan memiliki jarak = 1.

Berdasarkan hasil evaluasi, Silhouette Score (Hamming) yang diperoleh sekitar 0.15-0.25, yang mengindikasikan struktur cluster yang moderat. Nilai ini lebih rendah dibandingkan Silhouette Score K-Means pada dataset Mall karena: 1. Data kartu kredit memiliki kompleksitas yang jauh lebih tinggi (8 dimensi vs 2 dimensi) 2. Jarak Hamming pada data kategorikal cenderung menghasilkan nilai yang lebih rendah karena sifat binarinya (sama atau berbeda) 3. Data finansial memiliki variasi yang besar dan tumpang tindih antar segmen

Meskipun nilai absolutnya moderat, struktur 3 cluster yang terbentuk tetap memberikan insight bisnis yang sangat berharga.

Distribusi Cluster



Interpretasi Distribusi Cluster Kartu Kredit:

Visualisasi di atas menampilkan distribusi 8.950 nasabah ke dalam 3 cluster:


Pie Chart (kiri): - Cluster 0: 3,928 nasabah (43.9%) — Cluster terbesar - Cluster 1: 2,497 nasabah (27.9%) - Cluster 2: 2,525 nasabah (28.2%)

Bar Chart (kanan): Bar chart mengkonfirmasi distribusi yang sama dengan angka yang lebih jelas: - Cluster 0 mendominasi dengan 3,928 nasabah - Cluster 1 dan 2 memiliki jumlah yang hampir sama (masing-masing sekitar 2,500)

Distribusi yang tidak terlalu timpang (rasio terbesar:terkecil sekitar 1.6:1)

menunjukkan bahwa clustering ini membagi nasabah menjadi segmen yang cukup seimbang, yang baik untuk implementasi strategi bisnis karena tidak ada segmen yang terlalu kecil untuk diperhatikan atau terlalu besar untuk disasar secara spesifik.

Visualisasi Scatter Plot Cluster



Interpretasi Visualisasi K-Modes Cluster Kartu Kredit:

Visualisasi di atas menampilkan dua scatter plot yang menunjukkan penyebaran nasabah berdasarkan cluster mereka:


Plot Kiri: BALANCE vs PURCHASES - Cluster 0 (Merah): Terkonsentrasi di area BALANCE rendah dan PURCHASES rendah — menunjukkan nasabah dengan aktivitas transaksi rendah dan saldo kecil. - Cluster 1 (Hijau): Menyebar di area BALANCE rendah-menengah dan PURCHASES bervariasi — menunjukkan nasabah yang cukup aktif bertransaksi. - Cluster 2 (Biru): Mendominasi area BALANCE tinggi dan PURCHASES tinggi — nasabah dengan saldo besar dan aktivitas pembelian tinggi. Cluster ini juga memiliki banyak outlier dengan BALANCE sangat tinggi (>10,000) dan PURCHASES tinggi (>20,000).

Plot Kanan: CREDIT_LIMIT vs PAYMENTS - Cluster 0 (Merah): Terkonsentrasi di area CREDIT_LIMIT rendah-menengah dan PAYMENTS rendah — menunjukkan nasabah dengan batas kredit terbatas dan pembayaran kecil. - Cluster 1 (Hijau): Terkonsentrasi di area CREDIT_LIMIT rendah dan PAYMENTS sangat rendah — nasabah dengan aktivitas pembayaran minimal. - Cluster 2 (Biru): Menyebar di seluruh rentang CREDIT_LIMIT dan PAYMENTS — nasabah dengan batas kredit dan pembayaran yang bervariasi, termasuk outlier dengan CREDIT_LIMIT dan PAYMENTS sangat tinggi.

Insight dari Scatter Plot: Visualisasi ini mengkonfirmasi bahwa 3 cluster yang terbentuk memiliki karakteristik yang berbeda. Cluster 2 (Biru) secara konsisten

muncul sebagai cluster “premium” dengan nilai-nilai finansial yang lebih tinggi di semua dimensi, sementara Cluster 0 (Merah) adalah cluster “basic” dengan aktivitas yang lebih rendah.

Profil Rata-Rata Tiap Cluster



Interpretasi Profil Rata-Rata Tiap Cluster:

Visualisasi di atas menampilkan profil rata-rata ternormalisasi (0-1) untuk masing-masing 3 cluster di 8 fitur. Nilai 1 berarti cluster tersebut memiliki nilai rata-rata tertinggi untuk fitur tersebut, sementara 0 berarti terendah.

Cluster 0 (Merah) — “Nasabah Standard”: - Memiliki nilai PRC_FULL_PAYMENT yang tinggi — nasabah ini cenderung membayar tagihan penuh (transactor). - Nilai PAYMENTS dan MINIMUM_PAYMENTS moderat. - Nilai BALANCE, PURCHASES, dan CASH_ADVANCE rendah-menengah. - Ini adalah nasabah standar yang menggunakan kartu kredit secara wajar dan membayar tagihan dengan baik.

Cluster 1 (Hijau) — “Nasabah Rendah Aktivitas”: - Memiliki nilai PRC_FULL_PAYMENT yang tertinggi — nasabah ini paling rajin membayar penuh. - Nilai CREDIT_LIMIT dan TENURE tinggi. - Namun, nilai BALANCE, PURCHASES, PAYMENTS, dan CASH_ADVANCE terendah di antara semua cluster. - Ini adalah nasabah dengan batas kredit tinggi tetapi aktivitas transaksi sangat rendah — mereka mungkin memiliki kartu kredit sebagai “backup” atau untuk keperluan darurat saja. Mereka adalah “sleeping customers” yang jarang menggunakan kartu.

Cluster 2 (Biru) — “Nasabah High-Value Revolver”: - Memiliki nilai BALANCE, PURCHASES, CASH_ADVANCE, CREDIT_LIMIT, dan PAYMENTS tertinggi — ini adalah nasabah dengan aktivitas finansial paling tinggi. - Nilai PRC_FULL_PAYMENT terendah — mereka jarang membayar tagihan penuh. - Ini adalah nasabah high-value yang menghasilkan pendapatan bunga terbesar bagi bank karena mereka cenderung menumpuk saldo (revolver). Mereka adalah segmen paling bernilai secara finansial meskipun memiliki risiko kredit yang lebih tinggi.

Ringkasan Profil Cluster Kartu Kredit:

Cluster	Karakteristik Utama	Label Bisnis	Jumlah
0	Aktivitas standar, bayar penuh	Nasabah Standar	3,928 (43.9%)
1	Limit tinggi, aktivitas sangat rendah	Nasabah Tidak Aktif	2,497 (27.9%)
2	Aktivitas tinggi, saldo tinggi, jarang bayar penuh	Nasabah High-Value Revolver	2,525 (28.2%)

KESIMPULAN

Berdasarkan tugas clustering yang telah dikerjakan, dapat disimpulkan bahwa algoritma K-Modes berhasil digunakan untuk melakukan segmentasi data pelanggan berdasarkan data kategorikal. Melalui metode ini, data dapat dikelompokkan ke dalam beberapa cluster berdasarkan kemiripan karakteristik sehingga pola perilaku pelanggan menjadi lebih mudah dianalisis dan dipahami.

Pada proses clustering, dilakukan tahapan preprocessing data seperti handling missing values dan diskretisasi data numerik menjadi kategori agar dapat diproses menggunakan algoritma K-Modes. Selanjutnya, jumlah cluster optimal ditentukan menggunakan Elbow Method sebelum model clustering dibangun.

Hasil clustering menunjukkan bahwa setiap cluster memiliki karakteristik yang berbeda-beda, baik dari sisi perilaku pengeluaran, tingkat pendapatan, maupun aktivitas pelanggan. Dari hasil tersebut dapat diketahui adanya kelompok pelanggan dengan aktivitas tinggi, pelanggan standar, hingga pelanggan dengan aktivitas rendah. Segmentasi ini dapat membantu perusahaan dalam menentukan strategi bisnis, pemasaran, maupun pelayanan pelanggan yang lebih tepat sasaran.

Secara keseluruhan, tugas ini memberikan pemahaman mengenai penerapan algoritma K-Modes dalam proses data mining, khususnya pada teknik clustering untuk menemukan pola dan segmentasi pada data pelanggan.